Formato tidy para texto

HR Analytics: Teoría y Práctica

http://pablohaya.com/contact

01/2022

Instalación

El código ha sido probado en R version 4.1.2 (2021-11-01)

Es preciso instalar los siguientes paquetes:

- `install.packages("tidyverse")`
- `install.packages("tidytext")`
- `install.packages("textdata")`
- `install.packages("here")`
- `install.packages("reshape2")`

Referencias

Estas transparencias han tomado como referencia el libro de texto de **Text Mining with R** de Julia Sigle y David Robinson:

- https://www.tidytextmining.com

El conjunto de datos original ha sido extraído de:

- https://www.kaggle.com/saqlainrehan/employeesreviews-dataset

El formato tidy

El formato *tidy* es una manera de representar datos tabulados bastante cómoda para realizar análisis de datos. Este formato lo describe Hadley Wickham en detalle en Tidy Data, 2014.

En resumen, una tabla en formato '*tidy* cumple:

- Cada variable es una columna
- Cada observación es una fila (ej. un empleado)
- Cada tipo de observación es una tabla (ej. una tabla para los datos de empleado, y otra para sus comentarios)

P: ¿Cómo codificamos un texto en formato *tidy*?

R: En una tabla donde cada fila almacena un *token*

Un *token* es la unidad mínima con sentido que vamos a analizar. Normalmente se corresponde con una palabra, aunque podríamos definir *tokens* que agrupen más de una palabra (ej. n-gramas), u otra unidad de análisis como oraciones o párrafos.

El proceso de dividir un texto en *tokens* se llama *tokenización*.

Tomemos una revisión del archivo de datos.

```
text <- c('A company culture that encourages dissent, disco
          'Strong compensation, from benefits, to perks, to
          'Decent internal mobility opportunities.',
          'Employees are proud to work on globally impactfu
          )
text
```

```
## [1] "A company culture that encourages dissent, discours
## [2] "Strong compensation, from benefits, to perks, to ba
## [3] "Decent internal mobility opportunities."
## [4] "Employees are proud to work on globally impactful p
```

Convertimos el vector `text` en un *data frame* donde cada fila es una oración.

```
text_df <- tibble(line = 1:4, text = text)

text_df
```

```
## # A tibble: 4 x 2
##    line text
##   <int> <chr>
## 1     1 A company culture that encourages dissent, disco
## 2     2 Strong compensation, from benefits, to perks, to
## 3     3 Decent internal mobility opportunities.
## 4     4 Employees are proud to work on globally impactfu
```

La función que realiza la tokenización es `unnest_tokens()`

```
text_df %>%
  unnest_tokens(word, text)
```

```
## # A tibble: 33 x 2
##     line word
##    <int> <chr>
##  1     1 a
##  2     1 company
##  3     1 culture
##  4     1 that
##  5     1 encourages
##  6     1 dissent
##  7     1 discourse
##  8     1 transparency
##  9     1 and
## 10     1 fairness
## # ... with 23 more rows
```

`unnest_tokens()` tiene dos argumentos obligatorios.

1. Nombre de la columna que se va a crear para almacenar los `tokens`.
2. Nombre de la columna del data frame original que contiene el texto (`text` en el ejemplo)

Nótese que:

- Cualquier otra columna que tuviera el *data frame* se mantiene. En el ejemplo la columna `line`
- Los signos de puntuación han sido eliminados (ej. `dissent,`)
- Los `tokens` se convierten por defecto a minúsculas. Para deshabilitar esta opción tendríamos que añadir el parámetro `to_lower = FALSE`)

El parámetro `token` permite cambiar la unidad de tokenización (`word`, `sentence`, `ngram`...). Por defecto es `word`.

```
text_df %>%
  unnest_tokens(ngram, text, token="ngrams", n=2)
```

```
## # A tibble: 29 x 2
##     line ngram
##    <int> <chr>
##  1     1 a company
##  2     1 company culture
##  3     1 culture that
##  4     1 that encourages
##  5     1 encourages dissent
##  6     1 dissent discourse
##  7     1 discourse transparency
##  8     1 transparency and
##  9     1 and fairness
## 10     2 strong compensation
## # ... with 19 more rows
```

Primeros análisis

Vamos a realizar un ejemplo más sofistacado partiendo de un `dataset` que contiene 10 000 revisiones aleatorias extraídas del conjunto de datos original.

Leemos las revisiones de la columna `summary`

```
reviews <- read_csv(here("data/employee_reviews_10000.csv")

head(reviews$summary)
```

```
## [1] "Better for the short term"
## [2] "Head of Industry"
## [3] "overall is average on balance, but with great pluse
## [4] "Microsoft is a good place to work, the environment
## [5] "Good company, very stressful"
## [6] "Company"
```

y las tokenizamos:

```
tidy_reviews <- reviews %>%
  select(summary) %>%
  unnest_tokens(word, summary)

tidy_reviews
```

```
## # A tibble: 43,693 x 1
##   word
##   <chr>
## 1 better
## 2 for
## 3 the
## 4 short
## 5 term
## # ... with 43,688 more rows
```

obteniendo 43693 *tokens*

¿Qué *tokens* se utilizan más frecuentemente?

```
tidy_reviews %>%
  count(word, sort = TRUE)
```

```
## # A tibble: 4,024 x 2
##    word      n
##    <chr>   <int>
##  1 to       1737
##  2 great    1718
##  3 work     1569
##  4 company  1189
##  5 place    1090
##  6 good     1010
##  7 a         944
##  8 and       785
##  9 for       758
## 10 the       703
## # ... with 4,014 more rows
```

En algunos análisis es preciso limpiar este listado de palabras frecuentemente usadas (*stop words*). `tidyverse` incluye un listado proveniente de tres lexicones distintos.

```
data(stop_words)

stop_words
```

```
## # A tibble: 1,149 x 2
##   word      lexicon
##   <chr>     <chr>
## 1 a         SMART
## 2 a's       SMART
## 3 able      SMART
## 4 about     SMART
## 5 above     SMART
## 6 according SMART
## # ... with 1,143 more rows
```

Eliminar estas palabras de nuestros datos en formato *tidy* es muy sencillo.

```
tidy_reviews <- tidy_reviews %>%
  anti_join(stop_words)

tidy_reviews
```

```
## Joining, by = "word"
```

```
## # A tibble: 21,633 x 1
##   word
##   <chr>
## 1 short
## 2 term
## 3 head
## 4 industry
## 5 average
## 6 balance
## # ... with 21,627 more rows
```

Se han reducido a 21633 *tokens*, y han desaparecido las `stop words` de los *tokens* que aparecen más frecuentemente

```
tidy_reviews %>%
  count(word, sort = TRUE)
```

```
## # A tibble: 3,555 x 2
##    word            n
##    <chr>       <int>
##  1 company      1189
##  2 manager       495
##  3 amazon        382
##  4 experience    356
##  5 engineer      326
##  6 job           313
##  7 associate     312
##  8 software      273
##  9 people        245
## 10 apple         239
## # ... with 3,545 more rows
```

Es posible emplear uno solo de los lexicones ya que emplear los tres puede eliminar demasiadas palabras que dependiendo del tipo de texto puede ser útiles.

El siguiente código elimina las palabras frecuentes (`stopwords`) del lexicon `snowball`

```
data(stop_words)

stop_words_snowball <- stop_words %>%
                       filter(lexicon == "snowball")

tidy_reviews <- reviews %>%
                select(summary) %>%
                unnest_tokens(word, summary) %>%
                anti_join(stop_words_snowball)

tidy_reviews
```

```
## Joining, by = "word"
```

```
## # A tibble: 30,992 x 1
##    word
##    <chr>
##  1 better
##  2 short
##  3 term
##  4 head
##  5 industry
##  6 overall
##  7 average
##  8 balance
##  9 great
## 10 pluses
## # ... with 30,982 more rows
```

Este nuevo filtrado vemos que es menos *agresivo* (ej. vuelve a aparecer `great`):

```
tidy_reviews %>%
  count(word, sort = TRUE)
```

```
## # A tibble: 3,887 x 2
##    word            n
##    <chr>       <int>
##  1 great        1718
##  2 work         1569
##  3 company      1189
##  4 place        1090
##  5 good         1010
##  6 manager       495
##  7 amazon        382
##  8 experience    356
##  9 best          326
## 10 engineer      326
## # ... with 3,877 more rows
```

Para terminar como estos primeros análisis básicos visualizamos las frecuencia de palabra en una gráfica:

```
tidy_reviews %>%
  count(word, sort = TRUE) %>%
  filter(n > 10) %>%
  mutate(word = reorder(word, n)) %>%
  ggplot(aes(n, word)) +
    geom_col() +
    labs(y = NULL)
```

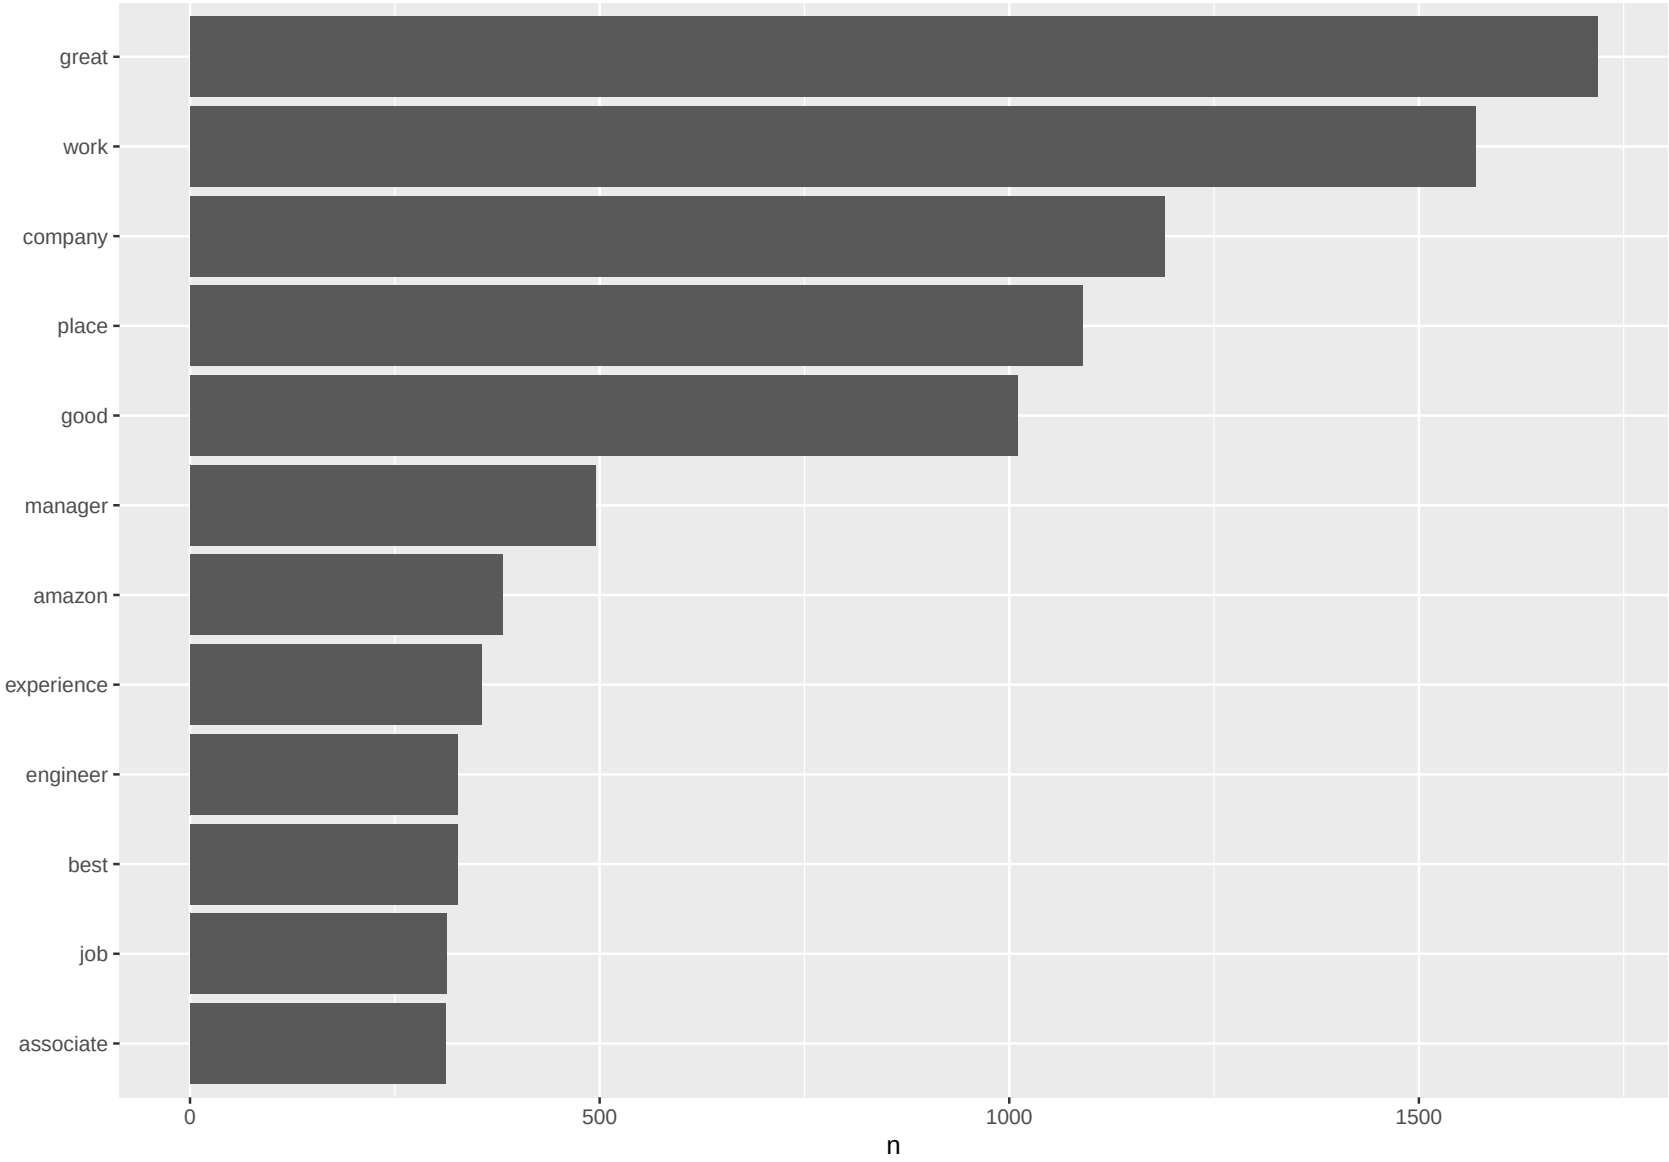
great
work
company
place
good
manager
amazon
experience
engineer
best
job
associate
0
500
1000
1500
n

A practicar

Ejercicio: Crear un archivo con una lista de palabras prohibidas propia (ej. 10). Emplear este archivo para realizar el filtrado.